




Klassifikation mit Support Vector Machines (SVM)



Seminar Digitale Nachrichtentechnik WS-2009
Johannes Leimig

Agenda

1. Grundlagen
2. Lineare SVM
 - 2.1 Hard-Margin
 - 2.2 Soft-Margin
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung

Agenda

1. **Grundlagen**
2. Lineare SVM
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung

Grundlagen

• Definition


- Support Vector Machines (SVM) sind Klassifikatoren, die eine Menge von Objekten so in Klassen unterteilen, dass um die Klassengrenzen herum ein möglichst breiter Bereich frei von Objekten bleibt
- SVM sind angelernte Klassifikatoren

• Motivation


- Klassifikation von Objekten zweier unterschiedlicher Klassen

• Aufgabenstellung

Lineare Klassifikation



Nichtlineare Klassifikation






2.1 Lineare SVM (Hard-Margin)

Eindeutig linear trennbare Klassen (Hard-Margin)

Problemstellung: Wie kann man diese Daten am besten klassifizieren?

Agenda

1. Grundlagen
2. **Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung



Idee: Diejenige Trennlinie ist am besten, die den größten Abstand zu den benachbarten Punkten der verschiedenen Klassen hat

Agenda

1. Grundlagen
- 2. Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung

2.1 Lineare SVM (Hard-Margin)


▪ Notation:

- Zwei-Klassen-Problem: pos./neg. Klasse $y_i = \pm 1$
- Lerndatensatz: $x_i \in \mathbb{R}^d$, $y_i \in \{-1, 1\}$, $i \in 1, \dots, n$
- Ebenengleichung
 - $H: w \cdot x_i + b = 0$
 - w : Normalenvektor
 - b : Verschiebung der Ebene
- Lagrange Funktion
 - Verknüpfung von Haupt- und Nebenbedingung

$$L(\alpha_i, x_i) = z(x_i) - \sum_{i=1}^n \alpha_i g(x_i)$$

2.1 Lineare SVM (Hard-Margin)

▪ Einführung der Hyperebene



$$H_1: w \cdot x_1 + b = 1$$

$$H_2: w \cdot x_2 + b = -1$$

$$H_0: w \cdot x_i + b = 0$$

- $w \cdot x_i + b \geq 1$, für $y_i = +1$ (1)
naheste positive Beispiele liegen auf

$$H_1: w \cdot x_1 + b = 1$$

- $w \cdot x_i + b \leq -1$ für $y_i = -1$ (2)
naheste negative Beispiele liegen auf

$$H_2: w \cdot x_2 + b = -1$$

- Zusammenfassen (1) und (2):


$$\rightarrow y_i \cdot (w \cdot x_i + b) - 1 \geq 0, \text{ für alle } i \quad (\text{Nebenbedingung})$$

Agenda

1. Grundlagen
2. **Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung

2.1 Lineare SVM (Hard-Margin)

- Berechnung des maximalen Rands



$$H_1: w \cdot x_1 + b = 1$$

$$H_2: w \cdot x_2 + b = -1$$

$$H_0: w \cdot x_i + b = 0$$

- Abstand zwischen H_1 und H_2 ergibt sich durch $H_1 - H_2$:
 - **Breite** = $2 / \|w\| \rightarrow \|w\|$ minimieren damit maximaler Rand (Maximum-Margin) entsteht
 - $y_i \cdot (w \cdot x_i + b) - 1 \geq 0$, Nebenbedingung muss zusätzlich erfüllt werden

→ Anwendung der Lagrange-Funktion

Agenda

1. Grundlagen
2. **Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung

2.1 Lineare SVM (Hard-Margin)

▪ Lagrange-Funktion

Formulierung des Primärproblems

- Für jede Nebenbedingung wird ein Lagrange-operator (α) eingeführt

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^n \alpha_i$$

- L ist bezüglich w und b zu minimieren und gegenüber α_i zu maximieren

Wir setzen

$$\frac{\partial}{\partial b} L(w, b, \alpha) = 0 \quad \text{und} \quad \frac{\partial}{\partial w} L(w, b, \alpha) = 0,$$

und erhalten

$$\sum_{i=1}^n \alpha_i y_i = 0 \quad \text{und} \quad w = \sum_{i=1}^n \alpha_i y_i x_i \quad (1)$$

Agenda

1. Grundlagen
2. **Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung

Agenda

1. Grundlagen
- 2. Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung

2.1 Lineare SVM (Hard-Margin)

▪ Lagrange-Funktion

Formulierung des Dualproblems

$$L_D(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j)$$

-
- L_D bezüglich α_i maximieren
 - Die Lösung des Dualproblems lässt sich mit Hilfe der Methoden der quadratischen Optimierung lösen.

Agenda

1. Grundlagen
2. **Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung

2.1 Lineare SVM (Hard-Margin)

▪ Karush-Kuhn-Tucker-Bedingung


Diese besagt: Eine optimale Lösung gilt wenn:

$$w = \sum_{i=1}^n \alpha_i y_i x_i \quad (1)$$

- $\alpha_i(y_i \cdot (w \cdot x_i + b) - 1) = 0$
- Da $\alpha_i \neq 0$ wegen (1) $\rightarrow y_i \cdot (w \cdot x_i + b) - 1 = 0$
- \rightarrow Lösung wird nur durch Punkte bestimmt die auf dem Rand zwischen der Hyperebene liegen (Support Vector oder sog. Stützvektor)

▪ Gesuchter Normalenvektor

$$w = \sum_{i=1}^{NSV} \alpha_i y_i x_i$$




- Berechne b durch Einsetzen eines Stützvektors in H_0
- Entscheidungsfunktion $y_i = \text{sgn}((w \cdot x_i) + b)$

2.1 Lineare SVM (Hard-Margin)

Agenda


1. Grundlagen
- 2. Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung



2.1 Lineare SVM (Hard-Margin)

Agenda

1. Grundlagen
- 2. Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung




2.2 Lineare SVM (Soft-Margin)

Nicht eindeutig linear trennbare Klassen (Soft-Margin)

Agenda

1. Grundlagen
- 2. Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung




- Gewichtungskonstante $C \geq \alpha_i \geq 0$

2.2 Lineare SVM (Soft-Margin)

■ Simulation des Soft-Margin Verfahrens

Agenda

1. Grundlagen
2. **Lineare SVM**
3. Nichtlineare SVM
4. Anwendungen
5. Zusammenfassung




■ Ergebnis:

- C muss so gewählt werden das ein Kompromiss zwischen Fehlertoleranz und Randbreite der beiden zu trennenden Klassen getroffen wird

3. Nichtlineare SVM

- Klassifikationsproblem



- Klassifikationsproblem nicht mehr linear lösbar → Wie kann dieses Problem gelöst werden?

Agenda

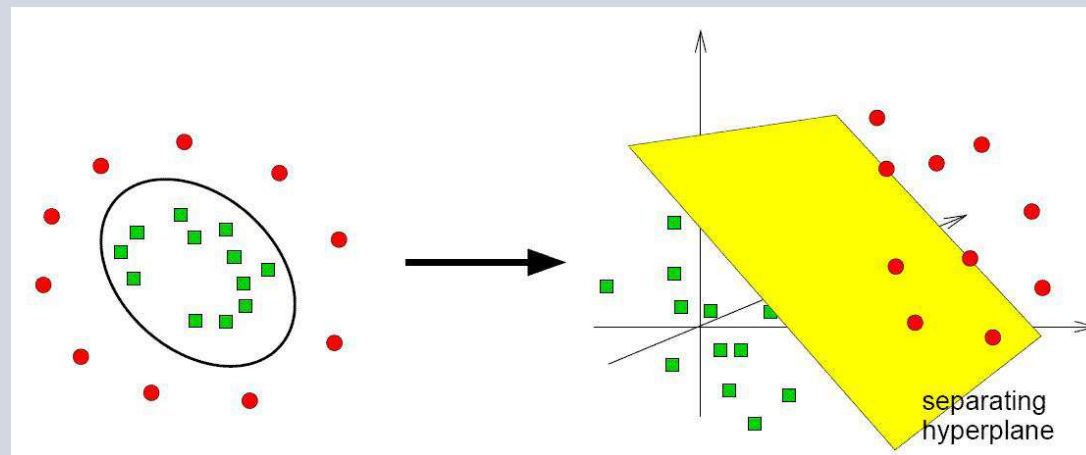
1. Grundlagen
2. Lineare SVM
- 3. Nichtlineare SVM**
4. Anwendungen
5. Zusammenfassung

3. Nichtlineare SVM

Agenda

1. Grundlagen
2. Lineare SVM
3. **Nichtlineare SVM**
4. Anwendungen
5. Zusammenfassung

- Transformation in einen mehrdimensionalen Raum (sog. Feature Space) in dem die Daten trennbar sind



- Problem: Sehr hoher Rechenaufwand bei der Transformation, deshalb Anwendung des Kerntricks

3. Nichtlineare SVM

- **Kerntrick**

- Erinnerung Dualproblem

$$L_D(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j)$$

- Dualproblem nur von Scalar-Produkt abhängig
 - Ersetzen des Scalar-Produktes durch Kern

$$L_D(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i \cdot x_j)$$

- Mögliche Kernfunktionen

- Lineare Kern: $K(x_i, x_j) = \langle x_i, x_j \rangle$
 - Polynome Kern: $K(x_i, x_j) = (\langle x_i, x_j \rangle + d_0)^n$
 - Gauß-Kern: $K(x_i, x_j) = \exp(-|x_i - x_j|^2 / 2\sigma^2)$

Agenda

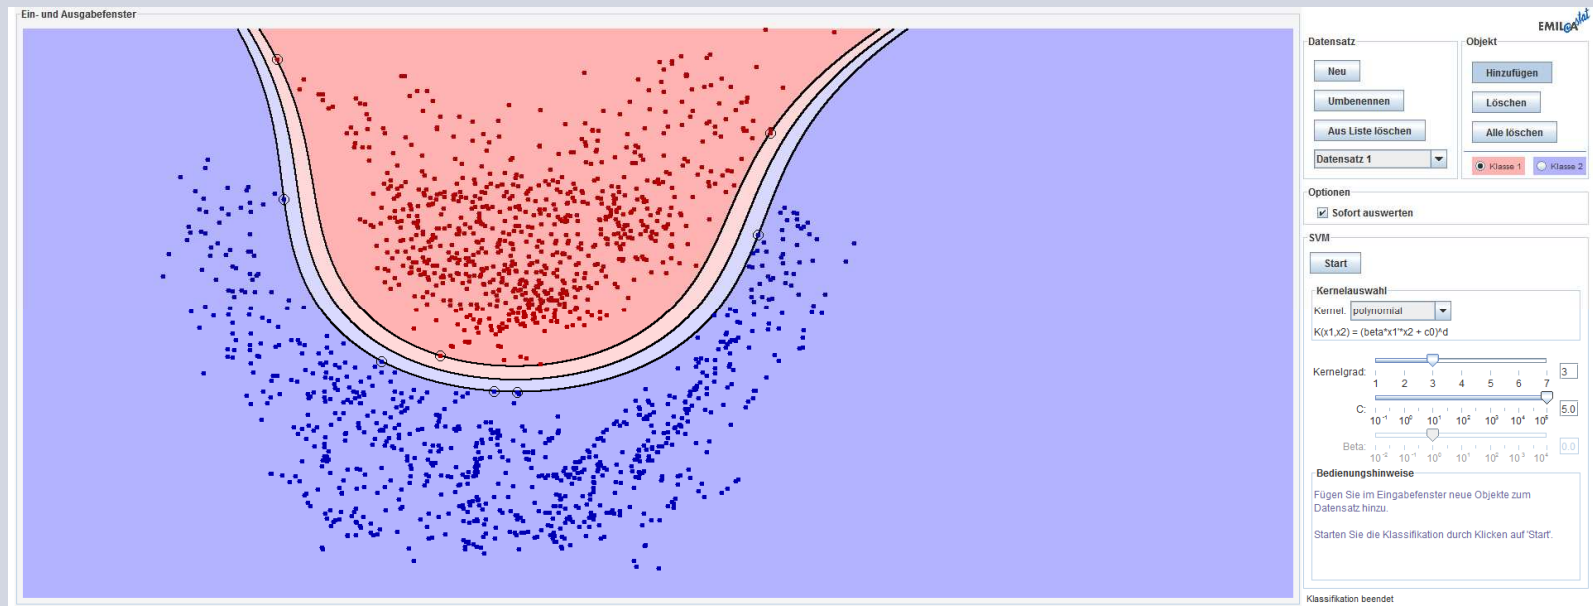
1. Grundlagen
2. Lineare SVM
3. **Nichtlineare SVM**
4. Anwendungen
5. Zusammenfassung

3. Nichtlineare SVM

▪ Simulation von nichtlinearen SVM

Agenda

1. Grundlagen
2. Lineare SVM
- 3. Nichtlineare SVM**
4. Anwendungen
5. Zusammenfassung



Anwendungen

- Medizintechnik
- Sprachverarbeitung
- Bildverarbeitung

Agenda

1. Grundlagen
2. Lineare SVM
3. Nichtlineare SVM
4. **Anwendungen**
5. Zusammenfassung

Anwendung

Objekterkennung, hier Fußgängererkennung

- ✍ Problem Komplexität von Objektklassen im Gegensatz zu herkömmlicher Mustererkennung
- ✍ Wahl von SVM als Klassifikator
- ✍ Dadurch bessere Leistung auf neuen Eingangsdaten



Zusammenfassung

Agenda

1. Grundlagen
2. Lineare SVM
3. Nichtlineare SVM
4. Anwendungen
5. **Zusammenfassung**

▪ Vorteile von SVM



- Klassifikation kann schnell und eindeutig mit geringen Restfehler durchgeführt werden
- Hohe Genauigkeit und geringe Fehlerwahrscheinlichkeit bei großen Rand
- Verwendung von relativ einfachen mathematischen Funktionen
- MatlabToolbox verfügbar

▪ Nachteile von SVM

- Lernvorgang ist zeitaufwendig
- Bei neuen Eingangsdaten muss die SVM neu angelernt werden
- Empirische Ermittlung der Kernfunktion und die Gewichtungskonstante C
- Gefahr der zu genauen Anpassung der Trainingsdaten durch die Wahl eines zu großen Gewichtungsfaktors

Danke für die Aufmerksamkeit!

Noch Fragen?



Seminar Digitale Nachrichtentechnik
Support Vector Machines (SVM)
Johannes Leimig

Literaturverzeichnis

- [1] Kuhlenschmidt B.: „Support Vector Machines“, Ausgewählte Kapitel des Softcomputing, Universität Münster, Lehrstuhl Informatik, 2008.
- [2] Böhmer M.: “Präsentation zu Support Vector Machines”, Universität Dortmund, Lehrstuhl Informatik, 2007.
- [3] Burges C.: “A Tutorial on Support Vector Machines for Pattern Recognition”, Data Mining and Knowledge Discovery 2, pages 121-167, 1998.
- [4] Burkhardt H.: “Vorlesung zu Support Vector Machines”, Universität Freiburg, Lehrstuhl Informatik, 2003.
- [5] http://www.ml.inf.ethz.ch/education/lectures_and_seminars/annex_estat/Classifier/JSupportVectorApplet.html, Simulation von Support Vector Machines, aufgerufen am 02.12.2009.
- [6] Fischer J.: “Support Vector Machines”, Seminar Statistische Lerntheorie und ihre Anwendungen, Universität Ulm, Lehrstuhl Informatik, 2007.
- [7] Schleif F.: „Machine Learning – Support Vector Machines –Teil 1“, Universität Leipzig, Medizinische Fakultät, 2007.
- [8] Eichhorn J.: “Grundlagen von Support Vector Machines und ihre Anwendung in der Bildverarbeitung”, Max-Planck-Institut für biologische Kybernetik, Tübingen, 2004.
- [9] Sluzhivoy A.: „Effiziente Methoden der Objekterkennung mit Support Vector Machines“, Diplomarbeit, Universität Duisburg-Essen, Fachbereich Mathematik, 2008.